



BestMarket

RetailInsight360

Simon

Doussin

01/06/2022

1) Contexte et expression du besoin



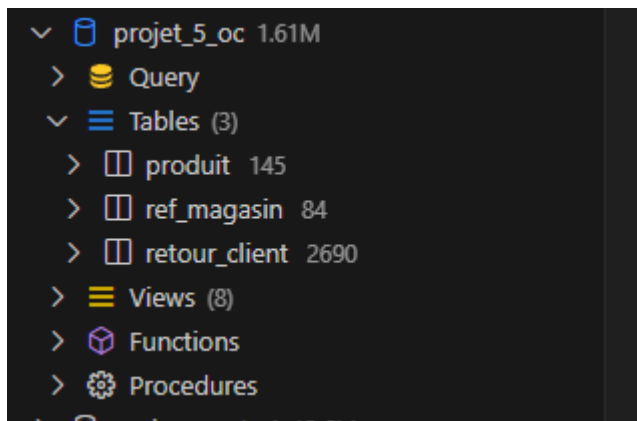
Bestmarket est une entreprise de grande distribution. Elle souhaite utiliser les données des retours et avis de ses clients pour améliorer la qualité de son réseau de magasins et améliorer son service client.

Expression des besoins par :

Client / Note / Magasin / Produit / NPS

2) Sauvegarde et stockage de la BDD

Utilisation de VSCode



Utilisation de python pour importer la 3^e table :

```
# Connexion à MySQL
connection = mysql.connector.connect(
    host="localhost",
    user="root",
    password="root",
    database="projet_5_oc"
)

cursor = connection.cursor()

# Nom de la table cible
table_name = "ref_magasin"

# Fonction pour remplacer les champs vides par NULL
def replace_empty_with_null(row):
    return [None if field.strip() == "" else field for field in row]

# Chemin du fichier CSV
csv_file_path = "C:/Users/.../projet_5_oc/ref_magasin.csv"

# Étape 1 : Détection de l'encodage
with open(csv_file_path, 'r') as file:
    result = charset.detect(file.read())
    detected_encoding = result['encoding']
    print(f"Encodage détecté : {detected_encoding}")

# Étape 2 : Lecture du fichier avec l'encodage détecté
with open(csv_file_path, mode='r', encoding=detected_encoding) as file:
    csv_data = csv.reader(file, delimiter=',')

    # Ignorer les en-têtes
    headers = next(csv_data, None)
    print(f"En-têtes ignorés : {headers}")

    # Exécute SQL pour insérer les données
    query = f"""
    INSERT IGNORE INTO {table_name}
    (ref_magasin_id, departement, departement_comune, libelle_de_comune, population, geo_point_2d)
    VALUES (%s, %s, %s, %s, %s, %s)
    """

    # Parcourir chaque ligne du fichier CSV
    for row in csv_data:
        # Remplacer les champs vides par NULL
        row = replace_empty_with_null(row)

        # Vérifier que la ligne contient bien 6 colonnes
```

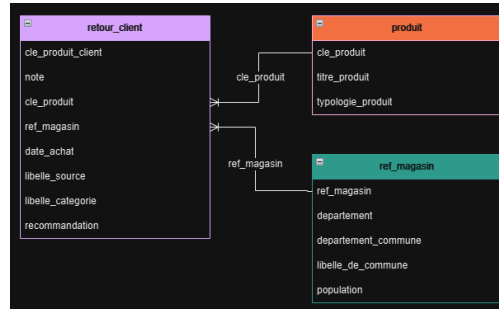
3) Méthodologie suivie



- 1) Création de la base de données
- 2) Importation des 2 tables (*retour_client* et *produit*)
- 3) Importation de la 3^e table (*ref_magasin*) via python
- 4) Création du schéma et du dictionnaire de donnée
- 5) Vérification de la qualité des données (doublon, valeur extrême)
- 6) Requête SQL

4) Requêtes SQL et Analyses

Création du schéma de donnée :

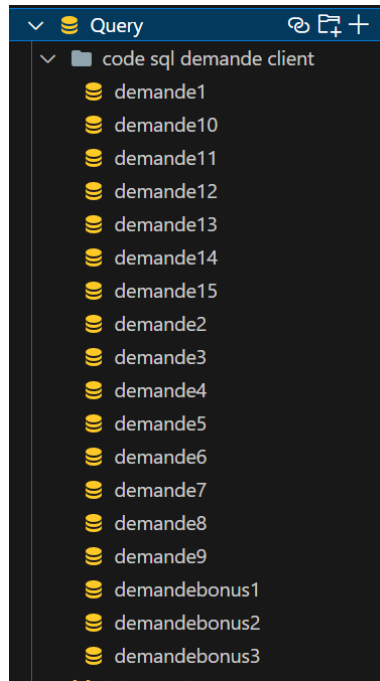


Création du dictionnaire de donnée :

	Nom du champs	Type de données	Taille	Contrainte	Description
Table Retour client	cle_retour_client	INT		Clé primaire	ID unique pour les retours clients
	note	INT			Note donnée par le client, comprise entre 0 et 10, la note est la réponse à la question : "Sur une échelle de 0 à 10 quelle est la probabilité que vous recommandiez notre entreprise à votre entourage ?"
	Clé_produit	INT			ID des produits
	ref_magasin	INT			ID des magasins
	date_achat	DATE			Date à laquelle l'achat du client a eu lieu
	libelle_source	CHAR	50		Libellé de la source d'où provient le retour client (Réseaux sociaux, téléphone, email)
	libelle_categorie	CHAR	50		Libellé de la catégorie du retour client (Drive, service après-vente, qualité produit, expérience en magasin, livraison)
	recommandation	CHAR			Recommandation laissée par le client à la question 'Recommandez vous l'entreprise?' True / False
Table Produit	cle_produit	INT		Clé primaire	ID unique pour les produits
	titre_produit	CHAR	50		Libellé des produits
	typologie_produit	INT			Typologie des produits (Alimentaire, High-tech etc...)
Table Ref_magasin	ref_magasin	INT		Clé primaire	ID unique pour les magasins
	departement	INT			Numéro du département
	departement_commune	INT			Code postal de la commune
	libelle_de_commune	CHAR	50		Nom de la commune
	population	INT			Nombre d'habitant

4) Requêtes SQL et Analyses

Traitement de la demande du client :



4) Requêtes SQL et Analyses : Client

Retour client :

```
1 ---- Demande n°10 : Sur quel mois a-t-on le plus de retour sur le service après-vente ? ----
2 SELECT MONTH(date_achat) as mois, COUNT(*) as nb_retour
3 FROM retour_client
4 WHERE libelle_categorie = 'service après-vente'
5 GROUP BY MONTH(date_achat)
6 ORDER BY nb_retour DESC 4ms
7 ;
```

mois	nb_retour
> 10	55
> 9	53
> 6	53
> 8	52
> 3	52
> 11	52
> 1	52
> 5	52
> 4	52
> 7	48
> 2	44
> 12	38

Les mois d'octobre, septembre et juin sont les mois ayant le plus de retour SAV.

```
1 ---- Demande bonus n°1 : Quel est le nombre de retour clients par source ? ----
2 SELECT libelle_source, COUNT(*) AS nb_retour
3 FROM retour_client
4 GROUP BY libelle_source
5 ORDER BY nb_retour DESC 6ms
6 ;
```

libelle_source	nb_retour
> email	1032
> réseaux sociaux	998
> téléphone	970

On compte 1032 retours clients par email, 998 par les réseaux sociaux et 970 par téléphones.

4) Requêtes SQL et Analyses : Client

Retour client :

```
---- Demande n°1 : nombre de retour clients sur la livraison ----
SELECT libelle_categorie, COUNT(*) as nombre
FROM retour_client
WHERE libelle_categorie = 'livraison' 4ms
;
```

libelle_categorie	nombre
livraison	639

Le nombre de retour client sur la livraison est de 639.
(drive : 611, service A-V : 603)

```
1 ---- Demande n°6 : Quel est le classement des départements par note ? ----
2 SELECT rm.departement, AVG(rc.note) as moyenne_note
3 FROM retour_client rc
4 LEFT JOIN ref_magasin rm ON rm.ref_magasin = rc.ref_magasin
5 GROUP BY rm.departement
6 ORDER BY moyenne_note DESC 7ms
7 ;
```

departement	moyenne_note
int	decimal
95	8.1388
75	8.1076
94	8.0567
91	8.0466
77	8.0420
92	8.0278
78	8.0169
93	7.9377

Les départements n°95, 75 et 94 ont, en moyenne, les meilleurs notes.

4) Requêtes SQL et Analyses : Client

Expérience client :

```
1 ---- Demande n°9 : Quel est le classement des jours de la semaine où l'expérience client est la meilleure expérience en magasin ? ----
2 SELECT DAY(date_achat) as jour, AVG(note) as moyenne_note
3 FROM retour_client
4 WHERE libelle_categorie = 'expérience en magasin'
5 GROUP BY DAY(date_achat)
6 ORDER BY moyenne_note DESC 6ms
7 ;
```

jour	moyenne_note
> 31	9.5000
> 10	8.5238
> 7	8.4737
> 13	8.4444
> 11	8.4286
> 2	8.4286
> 24	8.4000
> 6	8.2632
> 21	8.2381
> 3	8.2308
> 5	8.2000
> 18	8.1852
> 9	8.1333
> 16	8.1304
> 19	8.1176
> 25	8.1111

Il semblerait que le 31, le 10 et le 7 de chaque mois les clients ont, en moyenne, une meilleure expérience en magasin.

Recommandation client :

```
4 CREATE VIEW retour_client_reco_1 AS
5 SELECT *
6 FROM retour_client
7 WHERE recommandation = '1'
8 ;
9
10 SELECT ROUND((COUNT(rcr1.cle_retour_client) * 100) / COUNT(rc.cle_retour_client),2) as pourcentage_recommandation
11 FROM retour_client rc
12 LEFT JOIN retour_client_reco_1 rcr1 ON rc.cle_retour_client = rcr1.cle_retour_client
13 ORDER BY pourcentage_recommandation DESC 8ms
14 ;
15 # % recommandation client = 70,5
```

pourcentage_recomm
70.50

70,5% des clients recommande BestMarket.

4) Requêtes SQL et Analyses : Note

```
1  ---- Demande n°2 : Quelle est la liste des notes des clients sur les réseaux sociaux sur les TV ? --
2  SELECT rc.note, COUNT(*) as nombre
3  FROM retour_client rc
4  LEFT JOIN produit p ON p.cle_produit = rc.cle_produit
5  WHERE rc.libelle_source = 'réseaux sociaux'
6  AND p.titre_produit = 'TV'
7  GROUP BY rc.note 8ms
8  ;
```

Result(RO) X

Search Results

Cost: 8ms < 1 > Total 3

note	nombre
int	bigint
10	2
9	1
8	1

Sur les réseaux sociaux, les clients ont mis une note de 10 à 2 reprises, et une note de 9 et 8 à 1 reprise.

4) Requêtes SQL et Analyses : Note

Note selon le produit :

```
1  ---- Demande n°3 : Quelle est la note moyenne pour chaque catégorie de produit ?
2  SELECT p.typologie_produit, AVG(rc.note) as moyenne_note
3  FROM retour_client rc
4  LEFT JOIN produit p ON p.cle_produit = rc.cle_produit
5  GROUP BY p.typologie_produit
6  ORDER BY moyenne_note DESC 12ms
7  ;
8  ;
```

typologie_produit	moyenne_note
High-Tech	8.1607
Loisirs	8.0904
Alimentaire	8.0418
Maison	7.8507

Les produits high-techs ont une note moyenne de 8.2, les loisirs : 8.1, les produits alimentaires : 8 et les produits de maison : 7.85

```
9  SELECT p.titre_produit, AVG(rc.note) as moyenne_note
10 FROM retour_client rc
11 LEFT JOIN produit p ON p.cle_produit = rc.cle_produit
12 GROUP BY p.titre_produit
13 ORDER BY moyenne_note DESC 11ms
14 ;
```

titre_produit	moyenne_note
Plantes aromatiques surgelées	9.2000
Sodas	9.0000
Boissons alcoolisées	8.7895
Sauces au soja	8.7727
Aliments à base de plantes	8.7143
TV	8.7143
Aliments à base de plantes :	8.6842
Petit-déjeuners	8.6000
Concentré de tomate	8.6000
Plats au bœuf	8.5714

Les plantes aromatiques surgelées ont la meilleure note moyenne (9.2) suivi des sodas (9) et des boissons alcoolisées (8.8)

4) Requêtes SQL et Analyses : Note

```
2  ---- Demande n°8 : Quelle est la note moyenne sur l'ensemble des boissons ? ----
3  SELECT p.titre_produit, AVG(rc.note) as moyenne_note
4  FROM retour_client rc
5  LEFT JOIN produit p ON p.cle_produit = rc.cle_produit
6  WHERE p.titre_produit LIKE ('Boissons%')
7  GROUP BY p.titre_produit
8  ORDER BY moyenne_note DESC
9  ;
10
11 SELECT AVG(rc.note) as moyenne_note
12 FROM retour_client rc
13 LEFT JOIN produit p ON p.cle_produit = rc.cle_produit
14 WHERE p.titre_produit LIKE ('Boissons%')
15 ORDER BY moyenne_note DESC 7ms
16 ;
```

Result(RO) X

Q Search Results

moyenne_note decimal

8.3208

Parmi les boissons, celles alcoolisées ont les meilleurs notes en moyenne (8.8).

```
1  -- Liste des produit ayant des notes inférieure ou égale à 6 --
2  SELECT rc.ref_magasin, rc.libelle_categorie, rc.cle_produit, p.typologie_produit, p.titre_produit, rc.n
3  FROM retour_client rc
4  LEFT JOIN produit p ON p.cle_produit = rc.cle_produit
5  GROUP BY rc.ref_magasin, rc.libelle_categorie, rc.cle_produit, p.typologie_produit, p.titre_produit, rc.
6  HAVING rc.note <= 6
7  ORDER BY p.typologie_produit ASC, rc.note ASC 17ms
8  ;
```

Result(RO) X

Q Search Results

Cost: 17ms < 1 2 3 > Total 271

ref_magasin int	libelle_categorie string	cle_produit int	typologie_produit string	titre_produit string	note int
5	drive	115	Alimentaire	Viandes	0
57	service après-vente	63	Alimentaire	Légumineuses	0
20	drive	119	Alimentaire	Vinaigres d'alcools	0
58	livraison	36	Alimentaire	Exhausteurs de goût	0
36	livraison	80	Alimentaire	Pickles d'origine végétale	0
32	drive	47	Alimentaire	Fruits tropicaux	0
51	service après-vente	108	Alimentaire	Sucres	0
64	service après-vente	79	Alimentaire	Pickles	0
14	livraison	104	Alimentaire	Snacks salés	0

Voici une liste des produits qui ont une note inférieure à 6.

4) Requêtes SQL et Analyses : Magasin

```
1  ---- Demande n°4 : Quels sont les 5 magasins avec les meilleures notes moyennes ? ----
2  SELECT ref_magasin, AVG(note) as moyenne_note
3  FROM retour_client
4  GROUP BY ref_magasin
5  ORDER BY moyenne_note DESC
6  LIMIT 5  6ms
7  ;
```

ref_magasin int	moyenne_note
> 75	8.7273
> 78	8.5484
> 62	8.5000
> 23	8.4839
> 19	8.4524

Le magasin n°75, 78 et 62 ont les meilleures note moyenne.

```
1  ---- Demande n°5 : Quels sont les magasins qui ont plus de 12 feedbacks sur le drive ? ----
2  SELECT ref_magasin, COUNT(*) as nb_feedback
3  FROM retour_client
4  WHERE libelle_categorie = 'drive'
5  GROUP BY ref_magasin
6  HAVING nb_feedback > 12
7  ORDER BY nb_feedback DESC  5ms
8  ;
```

ref_magasin int	nb_feedback
> 67	14
> 63	13
> 45	13

Au niveau du drive : les magasins n°67, 63 et 45 ont plus de 12 feedbacks.

4) Requêtes SQL et Analyses : Magasin

```
16 --- Liste magasin dynamique selon note moyenne ---
17 CREATE VIEW note_moyenne AS
18 SELECT AVG(note) as moyenne_note
19 FROM retour_client
20 ;
21 SELECT rc.ref_magasin, AVG(rc.note) as moyenne_note_magasin
22 FROM retour_client rc
23 GROUP BY rc.ref_magasin
24 HAVING AVG(note) < (SELECT moyenne_note FROM note_moyenne)
25 ORDER BY moyenne_note_magasin DESC
26 ;
```

ref_magasin	moyenne_note_magasin
50	8.0513
36	8.0500
3	8.0357
47	8.0286

Voici la liste des magasins ayant une note inférieure à la moyenne.

```
1 ---- Demande bonus n°2 : Quels sont les 5 magasins avec le plus de feedbacks ? ----
2 SELECT ref_magasin, COUNT(*) AS nb_retour
3 FROM retour_client
4 GROUP BY ref_magasin
5 ORDER BY nb_retour DESC
6 LIMIT 5
7 ;
```

ref_magasin	nb_retour
29	55
6	49
80	47
5	45
63	44

Les magasins n°29, 6, 80, 5 et 63 ont eu le plus de feedbacks.

4) Requêtes SQL et Analyses : Produit

```
1 ---- Demande n°7 : Quelle est la typologie de produit qui apporte le meilleur service après-vente ? ----
2 SELECT p.typologie_produit, rc.libelle_categorie, AVG(rc.note) as moyenne_note
3 FROM retour_client rc
4 LEFT JOIN produit p ON p.cle_produit = rc.cle_produit
5 WHERE rc.libelle_categorie = 'service après-vente'
6 GROUP BY p.typologie_produit
7 ORDER BY moyenne_note DESC 7ms
8 ;
```

typologie_produit	libelle_categorie	moyenne_note
Loisirs	service après-vente	8.5135
High-Tech	service après-vente	8.1231
Alimentaire	service après-vente	8.0289
Maison	service après-vente	7.8824

Les produits de type loisirs apporte le meilleur service après-vente avec une note moyenne de 8.5.

```
20 ---- Demande n°13 : Quelles sont les typologies produits qui ont amélioré leur moyenne entre le 1er et 1
21 SELECT np2t.typologie_produit, np1t.moyenne_note_1er_tri, np2t.moyenne_note_2e_tri
22 FROM note_produit_1er_trimestre np1t
23 LEFT JOIN note_produit_2e_trimestre np2t ON np2t.typologie_produit = np1t.typologie_produit
24 HAVING np2t.moyenne_note_2e_tri > np1t.moyenne_note_1er_tri 13ms
25 ;
```

typologie_produit	moyenne_note_1er_tri	moyenne_note_2e_tri
Alimentaire	7.9932	8.0380
Loisirs	8.0000	8.1753

Les produits de type alimentaire et loisirs ont amélioré leur note moyenne entre le 1^{er} et le 2^e trimestre.

4) Requêtes SQL et Analyses : NPS

```
29 -- Score NPS --
30 SELECT *,
31     CASE
32         WHEN nps = 'promoteurs' THEN pourcentage_tg - (
33             SELECT pourcentage_tg
34             FROM nps_nb_pourcent
35             WHERE nps = 'détracteurs'
36         )
37         ELSE ''
38     END AS score_nps
39 FROM nps_nb_pourcent 39ms
40 ;
```

nps	nombre	pourcentage_tg	score_nps
passifs	1529	50.97	
promoteurs	1200	40.00	30.97
détracteurs	271	9.03	

Le score NPS est de 30,97, les clients sont donc en général satisfaits des magasins mais la fidélisation des clients reste à améliorer.

```
18 -- Score NPS par source --
19 SELECT *,
20     CASE
21         WHEN nps = 'promoteurs' AND libelle_source = 'email' THEN pourcentage_tg - (
22             SELECT pourcentage_tg
23             FROM nps_source_nb_pourcent
24             WHERE nps = 'détracteurs' AND libelle_source = 'email'
25         )
26         WHEN nps = 'promoteurs' AND libelle_source = 'réseaux sociaux' THEN pourcentage_tg - (
27             SELECT pourcentage_tg
28             FROM nps_source_nb_pourcent
29             WHERE nps = 'détracteurs' AND libelle_source = 'réseaux sociaux'
30         )
31         WHEN nps = 'promoteurs' AND libelle_source = 'téléphone' THEN pourcentage_tg - (
32             SELECT pourcentage_tg
33             FROM nps_source_nb_pourcent
34             WHERE nps = 'détracteurs' AND libelle_source = 'téléphone'
35         )
36         ELSE ''
37     END AS score_nps_source
38 FROM nps_source_nb_pourcent 19ms
39 ;
```

nps	libelle_source	nombre	pourcentage_tg	score_nps_source
promoteurs	email	387	37.50	29.65
passifs	email	564	54.65	
détracteurs	email	81	7.85	
promoteurs	réseaux sociaux	410	41.08	29.56
passifs	réseaux sociaux	473	47.39	
détracteurs	réseaux sociaux	115	11.52	
passifs	téléphone	492	50.72	
promoteurs	téléphone	403	41.55	33.82
détracteurs	téléphone	75	7.73	

5) Cohérence des données

Aucun doublon ou valeurs nulles dans les données, ni de valeurs aberrantes.

```
SELECT *  
FROM produit  
WHERE titre_produit IS NULL  
; #aucune valeur nulle
```

Exemple de requête pour les valeurs nulles.

```
--- Rechercher les doublons ---  
SELECT COUNT(*) as nb_doublon, typologie_produit, titre_produit  
FROM produit  
GROUP BY typologie_produit, titre_produit  
HAVING nb_doublon > 1  
; #aucun doublon
```

Exemple de requête pour les doublons.

```
--- Rechercher valeur aberrant ---  
SELECT DISTINCT (note)  
FROM retour_client  
; #aucune valeur aberrante  
SELECT MIN(note)  
FROM retour_client  
; #aucune valeur aberrante  
SELECT MAX(note)  
FROM retour_client  
; #aucune valeur aberrante
```

Exemple de requête pour les valeurs aberrantes.